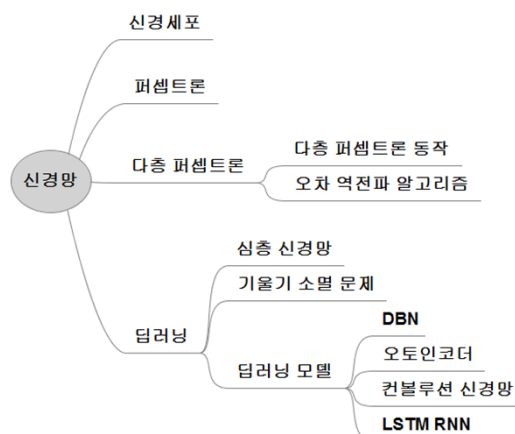


기계 학습

Part III


충북대학교 소프트웨어학과
이건명



8. 신경망

❖ 신경망(neural network, artificial neural network)

- 인간 두뇌에 대한 계산적 모델을 통해 인공지능을 구현하려는 분야
- 신경세포 (neuron)**



신경세포 8.6×10^{10} 개


신경연접 1.5×10^{14} 개

- 수상돌기(樹狀突起, dendrite)** : 다른 신경세포의 축삭돌기와 연결되어 전기화학적 신호를 받아들이는 부위
- 축삭돌기(軸索突起, axon)** : 수신한 전기화학적 신호의 합성결과 값이 특정 임계값이 이상이면 신호를 내보내는 부위.
- 신경연접(神經連接, synapse)** : 수상돌기와 축삭돌기 연결 부위
 - 전달되는 신호의 증폭 또는 감쇄

신경망

❖ 신경세포의 계산 모델


- 신경세포



McCulloch & Pitts, 1943
신경세포의 계산 모델

- 퍼셉트론(Perceptron)**


- 로젠블라트(Rosenblatt, 1957)이 제안한 학습가능한 신경망 모델




신경망

❖ 퍼셉트론(Perceptron)

▪ OR 연산을 수행하는 퍼셉트론



$$y = f(s) = f(\sum_{i=1}^2 w_i x_i + b) = f(\mathbf{w}\mathbf{x}^T) = x_1 + x_2 - 0.5$$




$p_1 (0,0): y = 0$
 $p_2 (1,0): y = 0$
 $p_3 (0,1): y = 0$
 $p_4 (1,1): y = 1$

신경망


❖ 퍼셉트론(Perceptron)

▪ 선형 분리가능 문제 (linearly separable problem)



▪ 선형 분리불가 문제 (linearly inseparable problem)

• XOR(exclusive OR) 문제





$(0,0): 0$
 $(1,0): 0$
 $(0,1): 0$
 $(1,1): 1$

Minsky & Papert 1969


신경망

❖ 다층 퍼셉트론(multilayer Perceptron, **MLP**)

- 여러 개의 퍼셉트론을 층 구조로 구성한 신경망 모델



$$y = f(s) = f(\sum_{i=1}^2 w_i x_i + b) = f(\mathbf{w}\mathbf{x}^T)$$



신경망


❖ 다층 퍼셉트론(multilayer Perceptron, **MLP**) – cont.

▪ 다층 퍼셉트론의 학습


- 입력-출력 (x_i, y_i) 의 학습데이터에 대해서 출력값 $f(x_i)$ 의 차이, **오차** (error)가 최소가 되도록 **가중치 w** 를 결정하는 것

▪ 학습 가능한 다층 퍼셉트론


- 학습알고리즘 : **오차역전파** 알고리즘 발표 (Rumelhart&McClelland 1986)
- 계단모양 전달함수를 미분가능한 시그모이드(sigmoid) 함수로 대체



계단 (step) 함수



시그모이드(sigmoid) 함수



$$f(s) = \frac{1}{1 + e^{-as}}$$

$$f'(s) = \frac{ae^{-as}}{(1 + e^{-as})^2} = af(s)(1 - f(s))$$

신경망

❖ 다층 퍼셉트론 MLP의 동작





Image source : Pascal Vincent

신경망

❖ 다층 퍼셉트론 MLP의 동작



입력 (x_1, x_2, \dots, x_d)


출력 (y_1, y_2, \dots, y_m)

$$\text{은닉층} \quad zsum_j = \sum_{i=1}^d u_{ij}x_i + u_{0j} \quad (1 \leq j \leq p)$$

$$z_j = f(zsum_j)$$


$$\text{출력층} \quad osum_k = \sum_{j=1}^p v_{jk}z_j + v_{0k} \quad (1 \leq k \leq m)$$

$$o_k = f(osum_k)$$



신경망

❖ 다층 퍼셉트론 MLP의 학습



입력 : (x_1, x_2, \dots, x_d)

기대 출력 : y_k

MLP 출력 : o_k

▪ 학습 목표

- 기대 출력과 MLP 출력이 최대한 비슷해지도록 가중치를 변경하는 것

$$E = \frac{1}{2} (o_k - y_k)^2$$

- 최대 경사법 (gradient descent method) 사용


$$v_{jk}^{(t+1)} = v_{jk}^{(t)} - \eta \frac{\partial E}{\partial v_{jk}}$$

$$u_{ij}^{(t+1)} = u_{ij}^{(t)} - \eta \frac{\partial E}{\partial u_{ij}}$$

신경망

❖ 다층 퍼셉트론 MLP의 학습

- 오차 역전파 알고리즘 (Error back propagation algorithm, Backprop algorithm)



입력 (x_1, x_2, \dots, x_d)

출력 (y_1, y_2, \dots, y_m)

$$E = \frac{1}{2} \sum_{k=1}^n (o_k - y_k)^2 \quad \text{오차함수}$$

$$v^{(t+1)} = v^{(t)} - \eta \frac{\partial E}{\partial v}$$

$$u^{(t+1)} = u^{(t)} - \eta \frac{\partial E}{\partial u}$$

$$\frac{\partial E}{\partial v_{jk}} = \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial v_{jk}} = (o_k - y_k) f'(osum_k) z_j = \delta_k z_j$$

$$\frac{\partial E}{\partial u_{ij}} = \frac{\partial E}{\partial z_j} \frac{\partial z_j}{\partial u_{ij}} = \sum_{k=1}^m \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial z_j} f'(zsum_j) x_i$$

$$= \sum_{k=1}^m (o_k - y_k) f'(osum_k) v_{jk} f'(zsum_j) x_i$$

$$= \sum_{k=1}^m \delta_k v_{jk} f'(zsum_j) x_i$$

$$osum_k = \sum_{j=1}^p v_{jk} z_j + v_{0k} \quad (1 \leq k \leq m)$$


$$o_k = f(osum_k)$$

$$zsum_j = \sum_{i=1}^d u_{ij} x_i + u_{0j} \quad (1 \leq j \leq p)$$

$$z_j = f(zsum_j)$$

신경망

- ❖ 다층 퍼셉트론 MLP의 학습
 - 오차 역전파 알고리즘 - cont.



$$f(x) = \frac{1}{1 + e^{-x}}$$

$$\frac{\partial f(x)}{\partial x} = \frac{e^{-x}}{1 + e^{-x}} = f(x)(1 - f(x))$$

$$y(x_1, x_2) = \frac{1}{1 + e^{-(w_0 + w_1 x_1 + w_2 x_2)}}$$

$$y(x_1, x_2) = \frac{1}{1 + e^{-(-1.0 - 3.0x_1 + x_2)}}$$

$$y(1.0, 2.0) = \frac{1}{1 + e^{-(-1.0 - 3.0(1.0) + 2.0)}} = 0.119$$

$$E = \frac{1}{2}(o - y)^2$$


$$\frac{\partial E}{\partial v_{jk}} = \frac{\partial E}{\partial o_k} \frac{\partial o_k}{\partial v_{jk}} = (o_k - y_k) f'(osum_k) z_j = \delta_k z_j$$

$$\begin{aligned} \frac{\partial E}{\partial u_{ij}} &= \sum_{k=1}^m (o_k - y_k) f'(osum_k) v_{jk} f'(zsum_j) x_i \\ &= \sum_{k=1}^m \delta_k v_{jk} f'(zsum_j) x_i \end{aligned}$$

$$v_{jk}^{(t+1)} = v_{jk}^{(t)} - \eta \frac{\partial E}{\partial v_{jk}} \quad u_{ij}^{(t+1)} = u_{ij}^{(t)} - \eta \frac{\partial E}{\partial u_{ij}}$$

신경망

- ❖ 소프트맥스 층 (softmax layer)
 - 최종 출력을 분류 확률(classification probability)로 변환하는 층
 - 출력의 합 = 1



$$y_k = \frac{e^{\sum_{j=1}^m w_{jk} x_j}}{\sum_{l=1}^n e^{\sum_{j=1}^m w_{jl} x_j}}$$

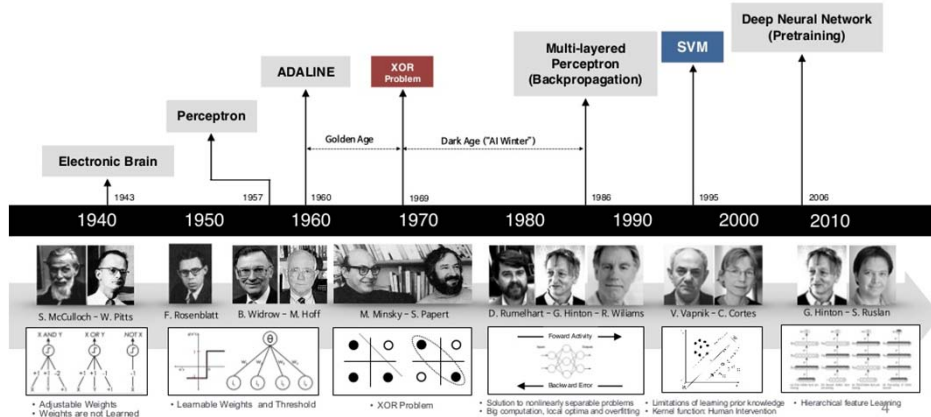
- 오차 함수
 - 목표 분포 p 와 출력분포 q 의 교차 엔트로피(cross entropy)

$$H(p, q) = - \sum_{i=1}^n [p(x_i) \log q(x_i) + (1 - p(x_i)) \log(1 - q(x_i))]$$

신경망의 역사

Brief History of Neural Network

DEVIEW
2015




출전: 이예하

9. 딥러닝


❖ 딥러닝(deep learning, 심층학습, 깊은 학습, 심화학습)

- 일반 신경망
 - 소수의 은닉층 포함



- 심층 신경망 (깊은 신경망, deep neural network)

- 다수의 은닉층 포함




출전: googLeNet (google)

딥러닝

❖ 심층 신경망 학습의 어려움

▪ 기울기 소멸 문제(vanishing gradient problem)

- 은닉층이 많은 다층 퍼셉트론에서, 출력층에서 아래 층으로 갈 수록 전달되는 오차가 크게 줄어들어, 학습이 되지 않는 현상



딥러닝

❖ 심층 신경망 학습 전략

▪ 사전 학습(pre-training)

- 가중치를 무작위로 초기화하는 대신
- 데이터를 사용하여 비지도학습에 의한 초기 가중치 결정

▪ 층(layer)간 노드 연결 수 제한

- 직전 층의 모든 노드와 연결하는 대신
- 일부 지역적 노드와 연결

▪ 가중치 공유

- 같은 층의 여러 노드가 동일한 가중치 사용

▪ 전달함수 변경

- 그래디언트(gradient) 값이 0에 가까워지는 것을 회피하기 위해
- 시그모이드(sigmoid) 함수 대신 부분적 선형 함수(linear function) 사용

▪ 부분적 가중치 학습

- 각 학습 단계에서 모든 가중치를 조정하는 대신
- 무작위로 선택한 일부 가중치만 조정


<http://neuralnetworksanddeeplearning.com/chap6.html>

딥러닝

❖ 일반 신경망과 심층 신경망


▪ 일반 신경망 모델

- 원시 데이터(original data)에서 직접 특징(handcrafted feature)을 추출해서 만든 **특징 벡터**(feature vector)를 입력으로 사용
- 특징 벡터들의 품질에 영향



▪ 심층 신경망

- 특징추출과 학습을 함께 수행
- 데이터로부터 **효과적인 특징**을 학습을 통해 추출 → 우수한 성능



딥러닝

❖ 딥러닝(deep learning, **심층학습**, 깊은 학습, 심화학습)

- 심층 신경망을 사용하여 **특징추출**과 **문제해결**을 위한 **학습**을 동시에 하는 기계학습 방법
- 대표적인 깊은 학습 신경망
 - **DBN**(Deep Belief Network, DBN)
 - **오토인코더**(autoencoder)
 - **컨볼루션 신경망**(Convolutional Neural Network, CNN)
 - **LSTM RNN**(Long short-term memory RNN)


9.1 Deep Belief Network

❖ DBN(Deep Belief Network) 모델

- Restricted Boltzmann Machine(제한된 볼츠만 머신, **RBM**)을 여러 층으로 쌓아 만든 심층 신경망

• RBM 모델


- 이진 입력 v 및 출력 h



Deep Belief Network

❖ DBN(Deep Belief Network) 모델

- RBM 모델의 동작




- 입력 v 를 입력층에 부가
- 입력 v 를 사용하여 은닉층의 확률 $p(h|v)$ 계산
- $p(h|v)$ 의 확률로 은닉층의 값 h 결정
- 은닉층 h 를 사용하여 입력층 확률 $p(v|h)$ 계산
- $p(v|h)$ 의 확률로 입력층의 값 v 결정

Deep Belief Network

❖ DBN 모델 – cont.

- RBN의 학습



- V 층의 노드값이 원래 입력값을 그대로 재구성하도록 즉, 같은 값이 나오도록 가중치를 결정하는 것
- (H 노드 계산 $\rightarrow V$ 노드 계산 $\rightarrow H$ 노드 계산 $\rightarrow V$ 노드 계산) 반복
- [V 노드 계산 $\rightarrow H$ 노드 계산] 단계에서 얻어진 v_i, h_j 의 값과 다음 단계의 v'_i, h'_j 차이를 최소화하도록 학습


$$w_{ij}^{(t+1)} = w_{ij}^{(t)} - \eta(\mathbf{v}_i \mathbf{h}_j - \mathbf{v}'_i \mathbf{h}'_j)$$

Deep Belief Network

❖ DBN 모델 – cont.

- DBN의 학습


- 층별로 학습이 점진적으로 이루어지는 **층별 학습**(layer-wise learning)



9.2 오토인코더

❖ 오토인코더(autoencoder)


- 입력층의 노드 개수와 출력층의 노드 개수가 같은 다층 퍼셉트론
- 입력과 출력을 동일하게 하여 학습
- 입력과 같은 출력이 나오도록 학습한 다층 퍼셉트론



오토인코더

❖ 오토인코더 - cont.

- 오토인코더의 학습




- 3번째 층을 입력에 대해 **특징 추출**(feature extraction)한 것으로 볼 수 있음

9.3 컨볼루션 신경망 CNN

❖ 컨볼루션 신경망(Convolutional Neural Network, CNN)

- 전반부 : 컨볼루션 연산을 수행하여 **특징 추출**
- 후반부 : 특징을 이용하여 **분류**
- 영상분류, 문자 인식 등 인식문제에 높은 성능



컨볼루션 신경망 CNN

❖ CNN의 연산

- 컨볼루션(convolution) 연산

| | | | | |
|----|----|----|----|----|
| 11 | 10 | 10 | 00 | 01 |
| 00 | 10 | 00 | 10 | 00 |
| 00 | 00 | 00 | 00 | 10 |
| 00 | 00 | 00 | 10 | 00 |
| 01 | 10 | 10 | 00 | 01 |

| | | |
|---|---|---|
| 1 | 0 | 1 |
| 0 | 1 | 0 |
| 1 | 0 | 1 |

| | | |
|---|---|---|
| 4 | 3 | 4 |
| 2 | 4 | 3 |
| 2 | 3 | 4 |

- Max pooling (subsampling) 연산

| | | | |
|---|---|---|---|
| 1 | 1 | 2 | 3 |
| 4 | 6 | 6 | 8 |
| 3 | 1 | 1 | 0 |
| 1 | 2 | 2 | 4 |

| | |
|---|---|
| 6 | 8 |
| 3 | 4 |

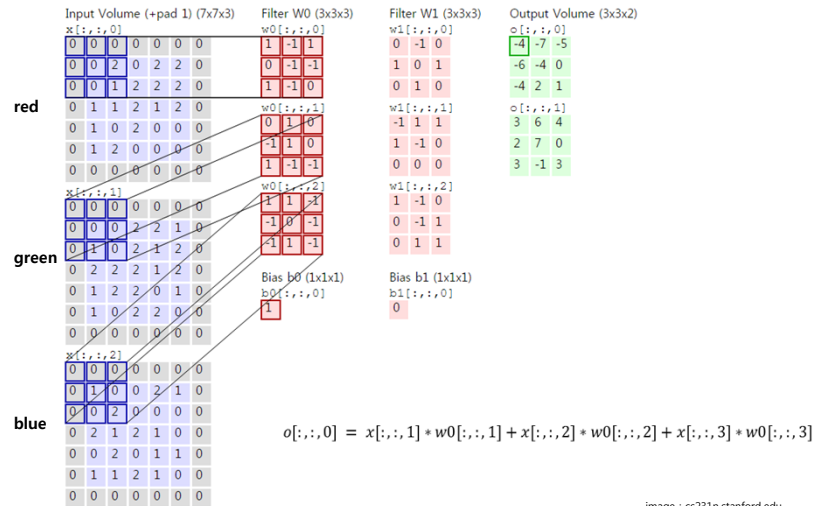
- ReLU (rectified Linear Unit)

- $f(x) = \max\{0, x\}$

컨볼루션 신경망 CNN

❖ CNN의 연산


▪ 3차원 입력에 대한 컨볼루션 연산의 예



컨볼루션 신경망 CNN

❖ CNN의 특징

- 지역적 연결(local connection)
 - 이전 층의 일부 뉴런에 대해서만 연결




- 가중치 공유(shared weight)
 - 같은 층에서는 동일한 컨볼루션 필터 사용

- 풀링(pooling) 사용
 - 위치가 다른 부분에 나온 유사한 특징을 결합
 - 특징공간을 축소



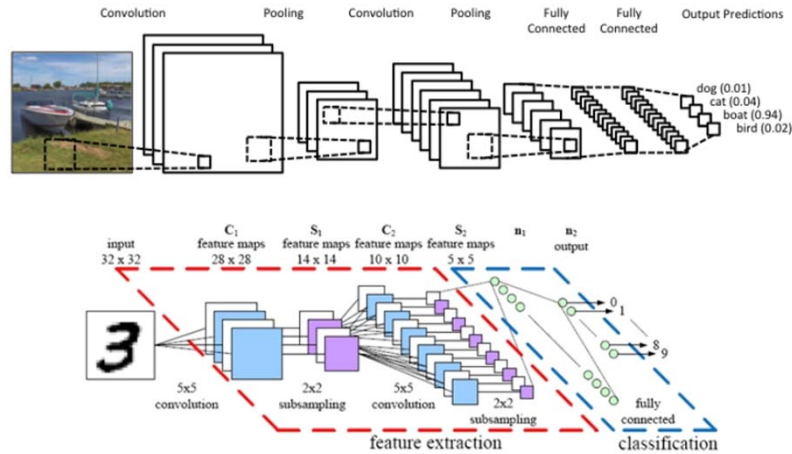
- 다층 사용
 - 추상화된 다층의 특징 추출



images : www.kdnuggets.com

컨볼루션 신경망 CNN

❖ CNN의 구조



images: www.kdnuggets.com <http://parse.ele.tue.nl/cluster/2/CNNArchitecture.jpg>

컨볼루션 신경망 CNN

❖ CNN을 이용한 영상 분류

Samoyed (16); Papillon (5.7); Pomeranian (2.7); Arctic fox (1.0); Eskimo dog (0.6); white wolf (0.4); Siberian husky (0.4)





Image : Nature

컨볼루션 신경망 CNN

❖ 컨볼루션 신경망 CNN의 학습


- 오차 역전파 알고리즘 사용
- dropout 방법
 - $1 - p$ 의 확률로 노드를 학습에서 무시
 - 노드에 연결된 에지가 없는 것으로 간주
 - 과적합(overfitting) 문제 완화
 - 학습 속도 향상



9.4 LSTM-RNN 모델

❖ RNN(Recurrent Neural Network, 재귀 신경망) 모델

- 이전 출력이 입력으로 들어가는 것이 있는 신경망



▪ RNN 학습

- 오차역전파 알고리즘 사용
- 기울기 소멸 문제(vanishing gradient problem) 심각


Image : Nature

LSTM-RNN 모델

❖ LSTM-RNN (Long Short-Term Memory Recurrent Neural Network)모델

▪ LSTM(Long Short-term memory) cell

- 뉴런 내에서 값을 저장하는 역할
- 값의 입력(input), 출력(output), 망각(forget)을 관리하는 문지기(gate) 회로를 가지고 있음
- 기울기 소멸 문제 해결



- 언어 모델(language model), 음성인식, 언어 번역 등에 우수한 성능

image: Alex Graves

딥러닝

❖ 깊은 학습의 특징

- 첫째, 여러 개의 은닉층을 갖는다.
- 둘째, 신경망에서 특징 추출을 담당한다.
- 셋째, 계층적으로 볼 때 위쪽으로 올라갈수록 더 추상화된 특징을 추출한다.
- 넷째, 학습이 점진적으로 이루어진다.
- 다섯째, 학습하는데 많은 계산량을 필요로 한다.
- 여섯째, 학습 데이터의 수가 많아져도 적용할 수 있기 때문에, 빅데이터 처리에도 사용할 수 있다.

딥러닝

❖ 딥러닝 개발 환경

▪ 라이브러리

- Caffe
- Torch
- Theano
- RNNLIB
- Cuda-ConvNet
- Pylarn
- DL4J
- TensorFlow

▪ 계산 환경

- CUDA
- Apache Spark

